

RAPPORT EXEMPLE · AUDIT INDÉPENDANT

Un backtest prometteur. Une décision qui résiste au réel.

Cas public : Kraken Alpha Agent

Reproduction · qualité des données · biais d'exécution · walk-forward · inférence ·
décision

VERDICT	RESEARCH_CLOSED
SIGNAL TRADABLE	0
OVERLAY RETENU	0 / 4

01 · DÉCISION

Synthèse exécutive

Le dépôt présentait encore un overlay de risque funding + basis comme piste utile après trente phases de recherche. L'audit a reconstruit les données, rejoué le pipeline et vérifié le moteur d'exécution. Le résultat positif disparaît.

DÉCISION

Arrêter la recherche sur cet univers

Aucun signal tradable, aucun candidat OOS, aucun overlay supporté.

1 058	872	0 / 4	2 190
tests automatisés	configurations OOS	overlays retenus	points funding reconstruits

Pourquoi cette décision est utile

- Elle évite de transformer un artefact de données en règle de risque mise en production.
- Elle clôt un budget de recherche déjà supérieur à 2 600 configurations sur le même univers.
- Elle distingue ce qui reste démontré - l'absence d'edge brut - des métriques historiques devenues caduques.

Périmètre et niveau d'assurance

Revue du code Python, des caches publics Binance, des rapports versionnés, des règles de risque, des tests et de la CI. Aucun ordre réel n'a été envoyé. Les caches reconstruits ne sont pas versionnés ; leur manifeste de volume et de provenance est conservé.

02 · POINT DE DÉPART

Ce que le backtest semblait raconter

Avant audit, quatre bundles dérivés sur quatre franchissaient le gate proceed_to_overlay. L'overlay ETH 4h était classé useful_overlay, avec un signal funding dont l'excès à 72 h paraissait positif et monotone.

Objet	Résultat publié	Lecture apparente
ETH 4h funding z-score	+0,786 point à 72 h (n=142)	Signal directionnel cohérent
BTC 4h funding z-score	+0,931 point à 72 h (n=126)	Confirmation inter-actifs
Gate dérivés	4 bundles sur 4 passent	Overlay à observer en forward
Observation	114 trades, block rate 0 %	Harnais opérationnel

Alerte méthodologique

Les chiffres étaient présents, mais la chaîne de preuve n'était pas complète : pagination de données, fraîcheur, tests d'inférence, définition du baseline et possibilité réelle de solder une position n'avaient pas été vérifiés ensemble.

Question d'audit

L'effet survit-il à une reconstruction complète des données et à des gates pré-enregistrés de puissance, direction, inférence, robustesse économique et out-of-sample ?

Standard de décision

- Un résultat positif ne suffit pas : il doit être alimenté par des données complètes et fraîches.
- Un signal doit survivre au placebo et à la correction Benjamini-Hochberg sur toute sa famille de tests.
- Une stratégie doit pouvoir exécuter ses sorties, y compris après le déclenchement d'un stop de risque.

03 · DIAGNOSTIC

Quatre défauts qui changent la décision

1. Données tronquées	Le cache funding s'arrêtait exactement à 1 000 lignes, la limite d'une page. Il ne couvrait qu'environ 30 % de la fenêtre de backtest.
2. Valeur gelée	Un forward-fill non borné propageait la dernière valeur connue. Le z-score devenait 0,0 et le composant funding se neutralisait silencieusement.
3. Gate permissif	Aucune p-value, aucun placebo et aucune correction multi-tests. Un excès négatif pris en valeur absolue pouvait être compté comme preuve favorable.
4. Sorties refusées	Cinq garde-fous du risk manager bloquaient aussi les ventes exit-only. Une position pouvait rester piégée après un stop ou un dépassement de plafond.

Ampleur observée dans les artefacts

Règle de risque	Déclenchements historiques	Effet avant correction
max_drawdown_pct	966	Sortie refusée après stop
max_position_fraction	874	Allègement refusé au-dessus du plafond
max_daily_loss_pct	150	Position bloquée après perte journalière
max_trades_per_day	41	Sortie refusée après quota
risk_denial_rate = 1,0	216 runs	Signature d'une position refusée à chaque barre

Le biais n'était pas simplement pessimiste. En hausse, une position impossible à solder pouvait embellir l'equity latente ; après retournement, elle pouvait amplifier la perte. Les métriques par run des phases concernées ne sont donc pas utilisables telles quelles.

04 · REJEU

Après reconstruction, l'effet disparaît

Les caches ont été reconstruits depuis les endpoints publics, puis le pipeline a été rejoué avec un plancher de puissance, une direction attendue pré-enregistrée, un bootstrap placebo et une correction BH-FDR.

Signal	n publié	n réel	72 h publié	72 h réel	p	q (BH)
ETH 4h	142	266	+0,786 pp	-0,177 pp	0,647	0,826
BTC 4h	126	243	+0,931 pp	+0,222 pp	0,428	0,965

Résultat statistique

Aucune cellule ne survit à Benjamini-Hochberg. L'effet ETH change de signe ; l'effet BTC est divisé par quatre. Le verdict devient not supported avant même l'analyse des coûts.

Effet sur les quatre bundles

Bundle	Publié	Rejou complet
BTC 4h	non_trivial=4 · proceed=true · overlay_only	non_trivial=0 · proceed=false · weak
ETH 4h	non_trivial=3 · proceed=true · overlay_only	non_trivial=0 · proceed=false · weak
BTC 1d	non_trivial=2 · proceed=true · blocked_data	non_trivial=0 · proceed=false · blocked_data
ETH 1d	non_trivial=2 · proceed=true · blocked_data	non_trivial=0 · proceed=false · blocked_data

La conclusion ne repose pas sur un seul backtest

Trois pipelines indépendants convergent vers zéro : 872 configurations moteur/walk-forward pour 0 survivant OOS ; 18 hypothèses event-study pour 0 candidat OOS et 0 rejet BH-FDR ; environ 600 runs de tournois/walk-forward bot pour 0 candidat papier.

05 · OBSERVATION

Pourquoi le forward test a été archivé

Le cron 4 h annoncé comme prêt n'a jamais été installé : une seule barre datée du 21 mai 2026, aucune donnée nouvelle trois mois plus tard, healthcheck en échec. Les 114 trades rapportés étaient un replay historique, pas une observation forward.

Baseline incorrect

Une boucle de replay au corps vide laissait le portefeuille standalone sans position. Le baseline ne pouvait jamais vendre et pouvait répéter les achats au lieu de n'agir qu'aux croisements.

Critère d'arrêt inerte

La comparaison d'equity face au standalone n'était jamais alimentée. Un critère de kill sur cinq ne pouvait pas se déclencher.

Décision opérationnelle

Ne pas relancer un cron qui collecterait des mesures invalides sur un objet déjà réfuté. Le harnais a été corrigé pour ne pas laisser de code trompeur, mais l'observation a été archivée et aucune micro-mise en production n'a été autorisée.

Ce qui a été corrigé

- Pagination complète du funding et statut explicite no_data au-delà de la fraîcheur autorisée.
- Gates de puissance, direction, placebo, p-value et BH-FDR dans le pipeline dérivés.
- Sorties exit-only autorisées par le risk manager sous les plafonds et stops.
- Replay standalone réel, persistance de sa courbe d'equity et critères d'arrêt évaluables.
- CI réparée ; suite de 1 058 tests et lint exécutables de bout en bout.

Ces corrections améliorent la qualité du logiciel. Elles ne transforment pas un résultat négatif en signal tradable.

06 · RECOMMANDATION

Plan d'action livré au décideur

Priorité	Action	Décision / critère de sortie
P0	Clôturer le track BTC/ETH/SOL OHLC + funding/basis/OI	Pas de phase 32 sur le même univers
P0	Ne pas engager de capital sur l'overlay	0/4 bundle supporté ; aucune observation forward
P1	Conserver le dépôt comme preuve méthodologique	Publier le verdict négatif et la provenance
P1	Séparer chiffres historiques caducs et preuves encore valides	Ne pas réutiliser les métriques par run phases 14-30
P2	Ne reprendre qu'avec une nouvelle source d'information	Nouvelle classe d'actifs, donnée ou mécanisme économique pré-enregistré

Valeur économique du verdict

Le rapport ne promet pas qu'une stratégie robuste gagnera. Il réduit le risque de financer une illusion : temps d'équipe, infrastructure, frais de marché, capital immobilisé et risque réputationnel.

Décision finale

RESEARCH_CLOSED. Le résultat solide du projet est l'absence d'edge démontrée de façon convergente, pas la découverte d'un signal exploitable.

Limites

- Ce rapport exemple synthétise un cas public ; il ne remplace pas les artefacts techniques complets.
- Le verdict porte sur l'univers, les données et les implémentations audités, pas sur tous les marchés possibles.
- Une absence de preuve n'est pas une preuve universelle d'absence ; elle suffit ici pour refuser la mise en risque.

07 · MÉTHODE

Ce qu'un audit Alpha Reality Check vérifie

Bloc	Contrôles représentatifs	Sortie
Reproductibilité	Environnement, seeds, versions, provenance, empreintes	Backtest rejouable
Données	Couverture, trous, timezone, pagination, ajustements, fraîcheur	Carte de qualité
Code	Look-ahead, leakage, états, exécution, sorties, sizing	Constats reproductibles
Économie	Frais, spread, slippage, turnover, capacité	Seuil de viabilité
Statistique	Puissance, placebos, multi-tests, stabilité, OOS	Niveau de preuve
Décision	Go, retravailler ou arrêter avec conditions	Verdict actionnable

Sources publiques de ce rapport exemple

- 1. reports/PHASE31_FINAL_VERDICT.md - décision finale, constats, métriques et limites.
- 2. reports/phase31_rerun/README.md - protocole du rejeu et comparaison publiée/réelle.
- 3. reports/phase31_rerun/derivatives_event_study_summary.json - résultats structurés des quatre bundles.
- 4. reports/phase31_rerun/cache_manifest.json - volumes et empreintes des caches reconstruits.

À propos

Alpha Reality Check est un service d'audit technique et méthodologique de stratégies quantitatives. Le livrable cherche activement les raisons pour lesquelles une performance pourrait ne pas exister et documente les conditions nécessaires à une décision de mise en risque.

Avertissement

Ce document est fourni à titre d'information et de démonstration. Il ne constitue ni un conseil en investissement, ni une recommandation d'achat ou de vente, ni une garantie de performance. Toute décision financière reste sous la responsabilité du lecteur.

Continuer · corriger · arrêter

Une décision documentée vaut mieux qu'une courbe séduisante.